

La risposta *Personal_Loan* di *UniversalBank* è binaria (0/1), cioè **categorica** (accettazione del prestito no/sì)

Può essere modellata da un modello **lineare**, in questo modo (dove $\underline{x}$ è il vettore dei predittori / feature):

$$Y = \begin{cases} 1 & \text{se } \underline{\beta}^T \underline{x} \geq \text{threshold} \\ 0 & \text{altrimenti} \end{cases}$$

Il metodo detto *Linear Discriminant Analysis* (LDA)

Nella previsione, tuttavia, la **probabilità** dell'evento può essere più utile da modellare dell'evento in sé.

Anziché modellare questa risposta direttamente, la regressione logistica modella appunto la probabilità che la risposta Y appartenga ad una determinata categoria (0/1). In particolare:

posterior
probability

$$p(\text{Personal_Loan} = 1 \mid \underline{x}) \in [0,1]$$

Intervallo
chiuso

dove 1 è appunto la «classe di interesse», cioè «è successo!» (qui, accettata la proposta di prestito).

Per semplicità di notazione sia:

$$p(\underline{X}) = p(\text{Personal_Loan} = 1 \mid \underline{x})$$

Come modelliamo questa probabilità?

Come si vede nel box qui a sx, $p(\underline{x})$ è la notazione *abbreviata* per la probabilità condizionata (ad $\underline{X} = \underline{x}$) di successo, meglio indicata come $p_+(\underline{x})$, oppure di fallimento ($p_-(\underline{x})$)

caso $q = 1$ (*Income*)


Il predittore
più
importante?

$$p(x) = \beta_0 + \beta_1 x \quad ?$$

La regressione lineare classica (OLS) modella male questa probabilità; si ottengono addirittura probabilità **negative** (per *Income* molto basso) oppure **>1** (per *Income* molto alto)!

Non è specifico solo di questo dataset; è intrinseco alla modellazione lineare di probabilità!

E' un approccio troppo semplicistico.



Ci serve una funzione che fornisca valori $\in [0 - 1]$ per qualsiasi x .

A prescindere dal ML, molte funzioni hanno questa proprietà; molto diffusa è la funzione **logistica**, una trasformazione **non-lineare** di x :

$$Y = f(x) = \frac{e^x}{1 + e^x} = \frac{1}{1 + e^{-x}}$$

In letteratura, la funzione logistica è spesso indicata con: $\phi(x)$ oppure $\sigma(x)$, anziché genericamente $f(x)$


una forma particolare di

$$Y = \frac{K}{1 + ce^{-hx}}$$
 con parametri **K=1**, **c=1** ed **h=1**

Una lenta crescita iniziale, poi un'accelerazione quasi lineare nel tratto centrale, ed infine un rallentamento asintotico verso il massimo (1 con i parametri scelti). Appiattisce i valori esterni su 0 oppure 1. Piccole variazioni di x intorno a 0 producono grandi variazioni di Y , non agli estremi.


Osservata da lontano, la funzione logistica approssima una funzione a gradino in cui Y cambia improvvisamente da 0 ad 1.

K=2, c=1 ed h=1:
Y è tra 0 ed 2.



curve ad S

K=1, c=1 ed h=1:
Y è tra 0 ed 1.



E' una curva importante perché molti fenomeni non possono crescere illimitatamente; fu introdotta nel 1838.


La funzione logistica, applicata al contesto della regressione, è: $\frac{1}{1+e^{-z}}$
 con $z = \beta_0 + \beta_1 x$ (detto *net input*), e quindi modella $p(x) \in [0 - 1]$:

$$\textcircled{1} \quad p(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$

$$= \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

è la **regressione logistica**,
 dal nome della funzione.
 $p(X) \in [0,1]!$

nel nostro esempio
 UniversalBank (con $q = 1$)



Con qualche manipolazione
 matematica (risoluzione rispetto
 all'esponenziale) si ha:

$$\textcircled{2} \quad \frac{p(x)}{1 - p(x)} = e^{\beta_0 + \beta_1 x}$$

$\textcircled{2}$ dà la relazione tra il
 predittore e gli odds: al
 crescere di β_1 gli odds
 aumentano

È una forma più comoda in alcuni casi;
 gli **odds di un evento** sono il rapporto
 tra $p(\text{evento})$ e $p(\text{non - evento})$.

Sono gli **odds** (trad. *pronostico, quotazione*), possono prendere qualsiasi valore tra 0 ed ∞ .
 Molto usati nel mondo delle scommesse ed in epidemiologia.

Sono gli «odds of x belonging to class 1». Cioè, il rapporto tra la probabilità di appartenere
 alla classe 1 rispetto a quella di appartenere alla classe 0.

Un valore vicino a 0 indica una probabilità (di accettazione) p molto bassa (num. $\rightarrow 0$).

Un valore vicino ad ∞ indica una probabilità (di accettazione) p molto alta (den. $\rightarrow 0$).

Ad esempio, con **odds** = 1: 4, in media 1 persona/azienda su 5 accetta, poiché $p(x) = 0.2$ implica **odds** = $0.2/(1 - 0.2) = 1/4$.

Allo stesso modo, con **odds** = 9, meglio detto 9: 1, 9 persone/aziende su 10 accettano,
 perché $p(x) = 0.9$ implica **odds** = $0.9/(1 - 0.9) = 9$

Odds = 3, meglio detto 3: 1, significa che p è tre volte più probabile di $(1 - p)$.

Al contrario, **odds** = 1 implica $p(x) = 0.5$. Odds 1: 1 sono chiamati *evens*.

Facendo il logaritmo di ❷ si ottiene:

$$\textcircled{3} \quad \log \left(\frac{p(x)}{1 - p(x)} \right) = \beta_0 + \beta_1 x$$

detti *log-odds* oppure *logit*

L'equazione ❸, che non è lineare in x , ha i log-odds **lineari (in x)**!



E dunque si può applicare ai log-odds, correttamente ed efficacemente, la tradizionale regressione lineare OLS.

NB. Ci sono quindi delle **relazioni matematiche** tra: i coefficienti β_i , $p(x)$, *odds*, *log – odds*, *odds – ratio*.

Le relazioni sono dirette ed inverse (*reverse*) .

Bisogna conoscerle e padroneggiarle.

Le principali funzioni matematiche di base utilizzate sono *exp* e *log_e* che è l'inversa di *exp*.



Gli *odds* possono avere qualsiasi valore non-negativo; *logit* può avere qualsiasi valore reale.

Come interpretare i coefficienti della regressione logistica?

Prime indicazioni (ampliate più avanti)

Nella regressione lineare semplice OLS, $\hat{\beta}_1$ rappresenta il cambiamento medio di Y (additivo) a fronte di un aumento unitario di X .

Nella regressione lineare multi-variata OLS, $\hat{\beta}_i$ rappresenta il cambiamento medio di Y (additivo) a fronte di un aumento unitario di X_i , tenendo costanti tutti gli altri predittori X_j con $j \neq i$ (non realistico se i predittori sono abbastanza correlati tra loro – un fenomeno molto frequente; realistico, invece, se si è regolarizzato il modello).

Nel caso di una variabile qualitativa X_i con k categorie, esplosa preliminarmente nel modello in $(k - 1)$ variabili dummy, $\hat{\beta}_{ik}$ rappresenta l'effetto addizionale medio su Y del livello k (*con $k \geq 1$*), rispetto al livello baseline $\hat{\beta}_{i0}$ (per il quale NON è riportato il coefficiente nell'output della regressione).

Il termine $\hat{\beta}_0$ rappresenta sempre il valore di risposta medio in assenza di predittori (aka, il modello nullo).

Nella regressione logistica, $\hat{\beta}_i$ rappresenta il cambiamento medio (additivo) non di Y , ma di *log – odds*(Y), a fronte di un cambiamento unitario di X_i , tenendo costanti gli altri predittori X_j con $j \neq i$.

Cioè, l'aumento di X_i di 1 moltiplica i log-odds per $\hat{\beta}_i$.

Ne consegue quindi che l'aumento di X_i di 1 moltiplica gli odds per $e^{\hat{\beta}_i}$ (e, caso più generale, l'aumento di X_i di *delta.x* moltiplica gli odds per $e^{\hat{\beta}_i \text{delta.x}}$).

Se X_i è una variabile dummy, l'interpretazione dei coefficienti è tecnicamente la medesima ma con un significato pratico diverso: $e^{\hat{\beta}_i}$ è il fattore moltiplicativo degli odds di accettare l'offerta con quella categoria **rispetto alla categoria base**.

Per fittare i coefficienti $\hat{\beta}_i$ ai dati si potrebbe usare il metodo OLS (nella [versione non-lineare](#)). Tuttavia, non ci sono i residui tra previsioni di probabilità e osservazioni binarie!

Inoltre, il metodo della *Maximum Likelihood Estimate* (MLE) ha delle proprietà statistiche migliori, ed è il metodo di stima *gold standard* per la Regressione Logistica.

L'idea base è la seguente: cerchiamo i coefficienti $\hat{\beta}_i$ tali che la probabilità di accettazione stimata $\hat{p}(\underline{x}_i)$ – relativa cioè alla riga i -esima –, corrisponda il più strettamente possibile allo stato 1 della persona/azienda i osservato.

Cioè, in altri termini, tornando al nostro esempio *UniversalBank* (con $q = 1$), cerchiamo i coefficienti $\hat{\beta}_0$ e $\hat{\beta}_1$ tali che, inserendoli nell'equazione ❶ vista prima, diano un numero vicino ad 1 per tutte le persone / aziende che hanno accettato, ed un numero vicino a 0 per tutte le persone / aziende che NON hanno accettato.

E' un problema di ottimizzazione della *likelihood* (rispetto alle variabili $\hat{\beta}_0$ e $\hat{\beta}_1$). Non confondere la likelihood («funzione di verosimiglianza» in italiano) con la probabilità a posteriori: entrambe sono probabilità condizionate, ma con variabili differenti!

Per semplicità, in realtà, si minimizza la *negative log-likelihood* perchè:

- il *log* riduce il rischio di *underflow* numerico, molto frequente quando le likelihood sono molto basse;
- il *log* trasforma i prodotti in somme, più facili da derivare (la log-likelihood è concava, la likelihood no!);
- con il segno – il problema diventa di minimo, affrontabile con il metodo del gradiente di discesa o di quasi Newton (che vedremo bene nel corso sulle reti neurali).

Gli stimatori MLE, grazie alle loro proprietà asintotiche, sono consistenti ed efficienti.

La stima ML è usata nella statistica base (101) per stimare i parametri di una distribuzione di probabilità; in pratica, essa trova la sua principale applicazione proprio nella Regressione Logistica.

In python, R, ecc esiste ottimo software che fitta facilmente i dati tramite il metodo MLE.

Si può dimostrare che la regressione OLS è un caso speciale di MLE.

Esperimento: di che sesso è la prossima persona che entrerà nel negozio?

Sia $M = 0, F = 1$.

In teoria, in mancanza di altre informazioni: $\Pr[0] = \Pr[1] = 0.5$.

Supponiamo di avere questi dati dal passato (le scorse ore, ad esempio):

Persona-1: 0

Persona-2: 1

Persona-3: 1

La media campionaria è: $\frac{\sum \text{persona}-i}{3} = 2/3$ ($>$ cutoff 0.5).

Cioè, la mia miglior previsione per la prossima persona è 1 (F).

Ma c'è un'altra modalità di calcolo della previsione (se gli arrivi sono indipendenti):

poiché: $\Pr[\text{persona}_1 = 0, \text{persona}_2 = 1, \text{persona}_3 = 1] = (1 - p)p^2$ (distribuzione binomiale, non conosco p):

il problema è trovare $p = \Pr[1]$ (la classe di interesse?) tale che:

$\Pr[\text{persona}_1 = 0, \text{persona}_2 = 1, \text{persona}_3 = 1]$ sia massima.

Cioè: $\hat{p} = \underset{p}{\operatorname{argmax}} (1 - p)p^2$.

$p = 0.5 \rightarrow (1 - p)p^2 = 0.5 * 0.25 = 0.125$ $p = 0.66 \rightarrow (1 - p)p^2 = 0.33 * 0.43 = 0.15$

E' una funzione polinomiale (quadratica) convessa, facile da derivare. La soluzione è nuovamente $\hat{p} = 2/3$, cioè F .

Stesso risultato, in un modo completamente diverso.

Il metodo MLE trova i parametri del modello che forniscono in media la probabilità $p+(x)$ più alta alle osservazioni $+$ (1) e la probabilità $p+(x)$ più bassa alle osservazioni $-$ (0).


$$2.36 * \text{CD_Account} + 0.17 * \text{Family} = 2.96$$

$$2.36 * \text{CD_Account} + 0.17 * \text{Family} = 2.96$$


Una retta è individuata univocamente da 2 punti.

Se $\text{CD_Account} = 0$, $\text{Family} = 2.96 / 0.17 = 17.4$.


Se $\text{Family} = 0$, $\text{CD_Account} = 2.96 / 2.36 = 1.25$




C'è una relazione (non-lineare) tra la distanza di un'osservazione dal DB e la sua $p \rightarrow$ vedi prossima slide .



Il guasto agli O-ring in 23 lanci degli shuttle prima del disastro del Challenger nel 1986. Il freddo favoriva i guasti!





I log-odds non sono di facile interpretazione. Si usano allora gli odds ②. Gli odds sono un rapporto (tra due probabilità). In quanto tali, essi non possono essere sommati (come avviene per la normale regressione lineare e quindi anche per i log-odds); sono modificabili invece per moltiplicazione. Il fattore moltiplicativo è e^{β_1} , detto **odds ratio** perché:

$$odds(x+1) = odds(x)e^{\beta_1} \Leftrightarrow e^{\beta_1} = \frac{odds(x+1)}{odds(x)}$$

Cioè e^{β_1} rappresenta appunto l'impatto moltiplicativo sugli odds che è determinato dal cambiamento unitario del valore del predittore x .

[$e^{\beta_1 \Delta x}$ è l'impatto moltiplicativo Δx (anziché unitario)].

In altri termini, e^{β_1} è lo *slope* di $x = \text{temperature}$ come odds (la notazione corretta è: $odds_{failure}(\text{temperature})$).

Per quanto riguarda $p_{failure}(\text{temperature})$, la funzione di maggior interesse, si ha:

se $\beta_1 > 0$, allora $e^{\beta_1} > 1$ e la funzione $p_{failure}(\text{temperature})$ è crescente;

se $\beta_1 < 0$, allora $e^{\beta_1} < 1$ e la funzione p è decrescente.

$e^{\beta_1} < 1$ determina quindi una diminuzione degli $odds_{failure}(\text{temperature})$ al crescere di x , $e^{\beta_1} > 1$ ne determina un aumento. Qui è $e^{\beta_1} = e^{-0.23} = 0.79$, cioè un aumento di 1 grado di *temperature* comporta una diminuzione degli odds (di $p_{failure}$) di 0.79.

NB. Sia odds che odds-ratio sono rapporti, ma di cosa diverse (non confondere).

β_0 e β_1 (additivi!) dei log-odds di failure ③

Gli odds di failure (qui riportati per comodità) diminuiscono del 21%

Logistic Regression Table

Predictor	Coef	SE Coef	Z	P	Odds Ratio
Constant	15.0429	7.37862	2.04	0.041	
temp	-0.232163	0.108236	-2.14	0.032	0.79

«odds di failure» ②

$$odds_{failure}(x) = \frac{p_{failure}(x)}{1 - p_{failure}(x)} = e^{\beta_0 + \beta_1 x} = e^{15.0429 - 0.2321x}$$

odds-ratio di failure


$$OR_{failure} = \frac{odds_{failure}(x+1)}{odds_{failure}(x)} = e^{-0.2321} = 0.7928$$

per eliminazione reciproca dei termini

probabilità di failure ①

$$p_{failure}(x) = \frac{1}{1 + e^{-(15.0429 - 0.23x)}}$$

Esempio in python per $x = 80$ ●:
 $1/(1 + np.exp(-(15.0429 - 0.23 * 80))) = 0.033$




$p_k(\underline{x})$: probabilità di appartenenza dell'osservazione $\underline{x} \in \mathcal{R}^q$ alla classe k , aka *propensity ad appartenere alla classe k* .

logit (purtroppo usato in modi un pò differenti in letteratura)


odds (termine molto diffuso nel mondo delle scommesse, nello sport e nella epidemiologia)

log-odds

odds-ratio



La Regressione Logistica (ottimizzazione iterativa)



La stima di $p_+(x)$ fatta dalla Regressione Logistica, in funzione di $f(x)$, cioè della distanza dal Decision Boundary.

Nel DB [cioè dove $(f(x)=0)$, $p_+(x)$ è circa 0.5 (è come lanciare una moneta). $p_+(x)$ varia in modo approssimativamente lineare vicino al DB (cioè piccoli valori di $f(x)$, positivi o negativi), ma poi approssima la certezza in modo asintotico, da un lato e dall'altro. Una parte importante del fit della Regressione Logistica è determinare lo *slope* di questo andamento lineare.